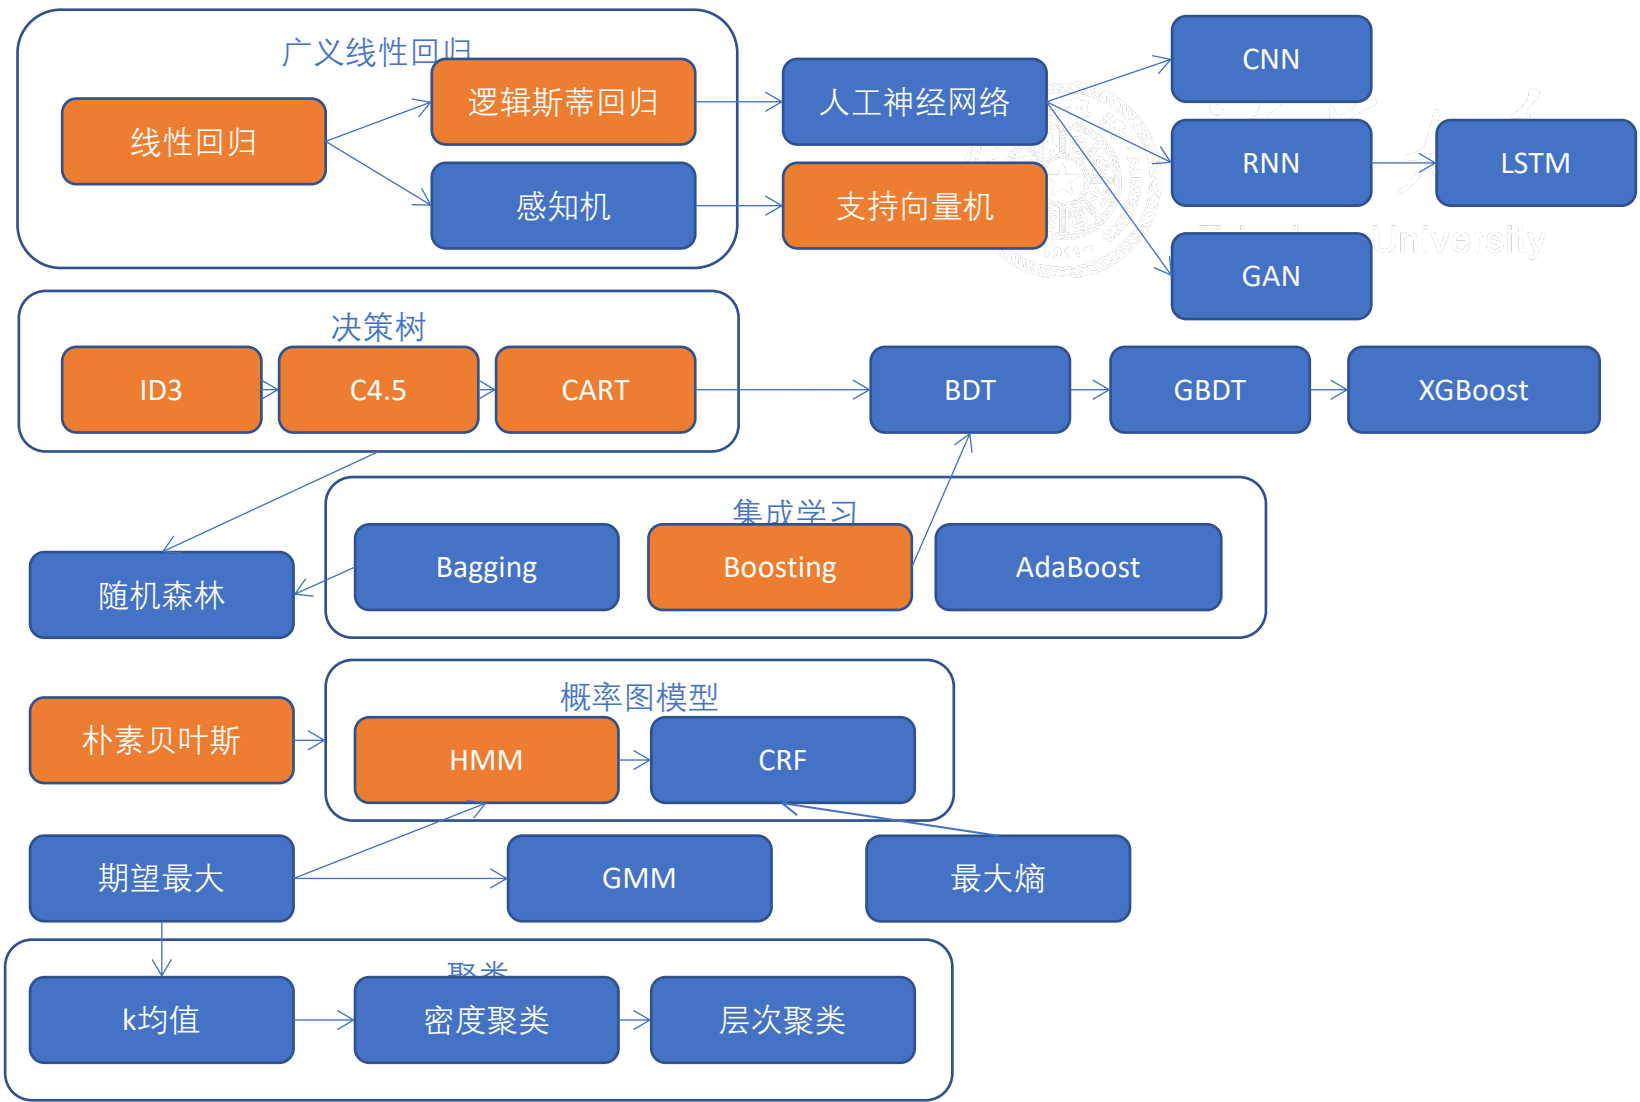


机器学习原理





清华大学
Tsinghua University

第九章

EM期望极大算法

EM算法的导出

- 为什么EM算法能近似实现对观测数据的极大似然估计？
- 极大化(不完全数据)Y关于参数 θ 的极大似然函数：

$$\begin{aligned} L(\theta) &= \log P(Y | \theta) = \log \sum_Z P(Y, Z | \theta) \\ &= \log \left(\sum_Z P(Y | Z, \theta) P(Z | \theta) \right) \end{aligned}$$

- 难点：有未观测数据，包含和的对数。
- EM通过迭代逐步近似极大化 $L(\theta)$, 希望 $L(\theta) > L(\theta^{(i)})$

EM算法的导出

$$\log \sum_j \lambda_j y_j \geq \sum_j \lambda_j \log y_j$$

- 考虑二者的差：

$$L(\theta) - L(\theta^{(i)}) = \log \left(\sum_Z P(Y|Z, \theta) P(Z|\theta) \right) - \log P(Y|\theta^{(i)})$$

- Jensen不等式：

$$\begin{aligned} L(\theta) - L(\theta^{(i)}) &= \log \left(\sum_Z P(Y|Z, \theta^{(i)}) \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Y|Z, \theta^{(i)})} \right) - \log P(Y|\theta^{(i)}) \\ &\geq \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)})} - \log P(Y|\theta^{(i)}) \\ &= \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)}) P(Y|\theta^{(i)})} \end{aligned}$$

EM算法的导出

- 令：
$$B(\theta, \theta^{(i)}) \triangleq L(\theta^{(i)}) + \sum_Z P(Z | Y, \theta^{(i)}) \log \frac{P(Y | Z, \theta) P(Z | \theta)}{P(Z | Y, \theta^{(i)}) P(Y | \theta^{(i)})}$$

- 则：
$$L(\theta) \geq B(\theta, \theta^{(i)})$$
$$L(\theta^{(i)}) = B(\theta^{(i)}, \theta^{(i)})$$

任何可以使 $B(\theta, \theta^{(i)})$ 增大的 θ ，也可以使 $L(\theta)$ 增大

- 选择：
$$\theta^{(i+1)} = \arg \max_{\theta} B(\theta, \theta^{(i)})$$


EM算法的导出

- 省去和 θ 无关的项：

$$\begin{aligned}\theta^{(i+1)} &= \arg \max_{\theta} \left(L(\theta^{(i)}) + \sum_Z P(Z | Y, \theta^{(i)}) \log \frac{P(Y | Z, \theta) P(Z | \theta)}{P(Z | Y, \theta^{(i)}) P(Y | \theta^{(i)})} \right) \\ &= \arg \max_{\theta} \left(\sum_Z P(Z | Y, \theta^{(i)}) \log (P(Y | Z, \theta) P(Z | \theta)) \right) \\ &= \arg \max_{\theta} \left(\sum_Z P(Z | Y, \theta^{(i)}) \log P(Y, Z | \theta) \right) \\ &= \arg \max_{\theta} Q(\theta, \theta^{(i)})\end{aligned}$$

EM算法的解释

$L(\theta)$ 开始



EM方法

输入：观测变量数据 Y , 隐变量数据 Z , 联合分布 $P(Y, Z | \Theta)$

条件分布 $P(Z | Y, \Theta)$

输出：模型参数 Θ

(1) 选择参数的初值 $\theta^{(0)}$, 开始迭代;

(2) E步: 记 $\theta^{(i)}$ 为第 i 次迭代参数 θ 的估计值,

在第 $i+1$ 次迭代的E步, 计算

$$\begin{aligned} Q(\theta, \theta^{(i)}) &= E_Z[\log P(Y, Z | \theta) | Y, \theta^{(i)}] \\ &= \sum_Z \log P(Y, Z | \theta) P(Z | Y, \theta^{(i)}) \end{aligned}$$

给定观测数据 Y 和当前参数估计 Θ

EM方法

(3) M步: 求使 $Q(\theta, \theta^{(i)})$ 极大化的 θ ,
确定第 $i+1$ 次迭代的参数的估计值 $\theta^{(i+1)}$

$$\theta^{(i+1)} = \arg \max_{\theta} Q(\theta, \theta^{(i)})$$

Q函数定义：

完全数据的对数似然函数 $\log P(Y, Z | \Theta)$ 关于在给定观测数据 Y 和当前函数 $\Theta^{(i)}$ 下对未观测数据 Z 的条件概率分布

$P(Z | Y, \Theta^{(i)})$, 的期望称为Q函数, 即：

$$Q(\theta, \theta^{(i)}) = E_Z[\log P(Y, Z | \theta) | Y, \theta^{(i)}]$$

EM方法

- 算法说明：
- 步骤3，完成一次迭代： $\Theta^{(i)}$ 到 $\Theta^{(i+1)}$ ，将证明每次迭代使似然函数增大或达到局部最大值。
- 步骤4，停止迭代的条件

$$\|\theta^{(i+1)} - \theta^{(i)}\| < \epsilon_1 \quad \text{或}$$

$$\|Q(\theta^{(i+1)}, \theta^{(i)}) - Q(\theta^{(i)}, \theta^{(i)})\| < \epsilon_2$$

EM在非监督学习中的应用

- 生成模型由联合概率分布 $P(X,Y)$ 表示，可以认为非监督学习训练数据是联合概率分布产生的数据， X 为观测数据， Y 为未观测数据。

EM算法在高斯混合模型学习中的应用

- 高斯混合模型：

- 概率分布模型； $P(y|\theta) = \sum_{k=1}^K \alpha_k \phi(y|\theta_k)$

- 系数： $\alpha_k \geq 0, \sum_{k=1}^K \alpha_k = 1$

- 高斯分布密度： $\phi(y|\theta_k) \quad \theta_k = (\mu_k, \sigma_k^2)$

- 第K个分模型： $\phi(y|\theta_k) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(y-\mu_k)^2}{2\sigma_k^2}\right)$

可任意高斯模型

高斯混合模型参数估计的EM算法

- 假设观测数据 y_1, y_2, \dots, y_N 由高斯混合模型生成：

$$P(y | \theta) = \sum_{k=1}^K \alpha_k \phi(y | \theta_k)$$
$$\theta = (\alpha_1, \alpha_2, \dots, \alpha_K; \theta_1, \theta_2, \dots, \theta_K)$$

- 用EM算法估计参数；
- 1、明确隐变量，写出完全数据的对数似然函数：
 - 设想观测数据 y_i 是依概率 α_k 选择第 k 个高斯分模型 $\phi(y | \theta_k)$ 生成，隐变量

$$\gamma_{jk} = \begin{cases} 1, & \text{第 } j \text{ 个观测来自第 } k \text{ 个分模型} \\ 0, & \text{否则} \end{cases}$$

EM算法在高斯混合模型学习中的应用

- 1、明确隐变量，写出完全数据的对数似然函数：

- 完全数据： $(y_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jK}), j=1, 2, \dots, N$

- 似然函数： $P(y, \gamma | \theta) = \prod_{j=1}^N P(y_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jK} | \theta)$

$$\begin{aligned} n_k &= \sum_{j=1}^N \gamma_{jk} \\ \sum_{k=1}^K n_k &= N \\ &= \prod_{k=1}^K \prod_{j=1}^N [\alpha_k \phi(y_j | \theta_k)]^{\gamma_{jk}} \\ &= \prod_{k=1}^K \alpha_k^{n_k} \prod_{j=1}^N [\phi(y_j | \theta_k)]^{\gamma_{jk}} \\ &= \prod_{k=1}^K \alpha_k^{n_k} \prod_{j=1}^N \left[\frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(y_j - \mu_k)^2}{2\sigma_k^2}\right) \right]^{\gamma_{jk}} \end{aligned}$$

EM算法在高斯混合模型学习中的应用

- 1、明确隐变量，写出完全数据的对数似然函数：

$$\log P(y, \gamma | \theta) = \sum_{k=1}^K n_k \log \alpha_k + \sum_{j=1}^N \gamma_{jk} \left[\log \left(\frac{1}{\sqrt{2\pi}} \right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right]$$

EM算法在高斯混合模型学习中的应用

- 2、EM算法的E步，确定Q函数

$$\begin{aligned} Q(\theta, \theta^{(i)}) &= E[\log P(y, \gamma | \theta) | y, \theta^{(i)}] \\ &= E \left\{ \sum_{k=1}^K n_k \log \alpha_k + \sum_{j=1}^N \gamma_{jk} \left[\log \left(\frac{1}{\sqrt{2\pi}} \right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right] \right\} \\ &= \sum_{k=1}^K \left\{ \sum_{j=1}^N (E \gamma_{jk}) \log \alpha_k + \sum_{j=1}^N (E \gamma_{jk}) \left[\log \left(\frac{1}{\sqrt{2\pi}} \right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right] \right\} \end{aligned}$$

需要计算 $E(\gamma_{jk} | y, \theta)$ ，记为 $\hat{\gamma}_{jk}$

- 第j个观测数据来自第k个分模型的概率，称为分模型k对观测数据 y_j 的响应度。

EM算法在高斯混合模型学习中的应用

- 2、EM算法的E步，确定Q函数

$$\begin{aligned}\hat{\gamma}_{jk} &= E(\gamma_{jk} | y, \theta) = P(\gamma_{jk} = 1 | y, \theta) \\ &= \frac{P(\gamma_{jk} = 1, y_j | \theta)}{\sum_{k=1}^K P(\gamma_{jk} = 1, y_j | \theta)} \\ &= \frac{P(y_j | \gamma_{jk} = 1, \theta) P(\gamma_{jk} = 1 | \theta)}{\sum_{k=1}^K P(y_j | \gamma_{jk} = 1, \theta) P(\gamma_{jk} = 1 | \theta)} \\ &= \frac{\alpha_k \phi(y_j | \theta_k)}{\sum_{k=1}^K \alpha_k \phi(y_j | \theta_k)}, \quad j = 1, 2, \dots, N; \quad k = 1, 2, \dots, K\end{aligned}$$

EM算法在高斯混合模型学习中的应用

- 2、EM算法的E步，确定Q函数

将 $\hat{\gamma}_{jk} = E\gamma_{jk}$ 及 $n_k = \sum_{j=1}^N E\gamma_{jk}$ 代入

$$Q(\theta, \theta^{(i)}) = \sum_{k=1}^K n_k \log \alpha_k + \sum_{k=1}^K \hat{\gamma}_{jk} \left[\log \left(\frac{1}{\sqrt{2\pi}} \right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right]$$

EM算法在高斯混合模型学习中的应用

- 3、确定EM算法的M步：

- 求： $\theta^{(i+1)} = \arg \max_{\theta} Q(\theta, \theta^{(i)})$

用 $\hat{\mu}_k$, $\hat{\sigma}_k^2$ 及 $\hat{\alpha}_k$, $k=1,2,\dots,K$, 表示 $\theta^{(i+1)}$

- 采用求导的方法：

$$\hat{\mu}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} y_j}{\sum_{j=1}^N \hat{\gamma}_{jk}}$$

$$\hat{\sigma}_k^2 = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} (y_j - \mu_k)^2}{\sum_{j=1}^N \hat{\gamma}_{jk}}$$

$$\hat{\alpha}_k = \frac{n_k}{N} = \frac{\sum_{j=1}^N \hat{\gamma}_{jk}}{N}$$

高斯混合模型参数估计的EM算法

- 输入：观测数据 y_1, y_2, \dots, y_N , 高斯混合模型
- 输出：高斯混合模型参数
- 1、设定初始值开始迭代
- 2、E步，响应度计算

$$\hat{\gamma}_{jk} = \frac{\alpha_k \phi(y_j | \theta_k)}{\sum_{k=1}^K \alpha_k \phi(y_j | \theta_k)}$$

高斯混合模型参数估计的EM算法

- 输入：观测数据 y_1, y_2, \dots, y_N , 高斯混合模型
- 输出：高斯混合模型参数
- 3、M步，计算新一轮迭代的模型参数：

$$\hat{\mu}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} y_j}{\sum_{j=1}^N \hat{\gamma}_{jk}} \quad \hat{\sigma}_k^2 = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} (y_j - \mu_k)^2}{\sum_{j=1}^N \hat{\gamma}_{jk}} \quad \hat{\alpha}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk}}{N}$$

- 4、重复2，3步直到收敛

• Q & A

7 七月在线
JULYEDU.COM

从零学AI的路线图：挑战年薪40万

通过七月在线《机器学习集训营》可解锁全部技能 超过2000人的成功经验：从零学AI、传统IT转型AI

- 核心语法：循环 判断 控制
- 函数与面向对象
- 迭代器、生成器、装饰器

Python基础

数据分析

- 科学计算之numpy
- 数据分析之pandas
- 数据分析实战（美国大选、房价预测）

数据结构

- 链表、队列、堆栈
- 字符串和数组
- 哈希表、树、图
- 查找与排序：增删改查
- 分治递归回溯
- 贪心和动态规划
- 概率与组合

大数据

- Hadoop 基础(HDFS与YARN)
- MapReduce与Hive SQL
- 分布式数据库Hbase
- Spark与Flink

机器学习

- 机器学习的基本流程
- 经典模型：线性模型、决策树
- 常考模型：SVM与XGBoost
- 应用模型：HMM与CRF
- 特征工程：数据处理、模型构建/调优
- 上线部署：模型调参与模型评估
- 项目实战：图像检索、金融风控

深度学习

- 核心模型：CNN RNN LSTM
- CV应用：Two-Stage和One-Stage框架
- 项目实战：调参、优化、模型压缩、蒸馏收敛
- 框架应用：TensorFlow与Pytorch

CV NLP 推荐的企业级项目实战

- 大规模跨境追踪/重识别（ReID）
- 人体关节点提取
- 智能客服系统
- 人体关节点提取
- 电商平台的商品推荐系统
- 从零开整电影推荐网站
- 简历指导、面试辅导、就业内推

CV 企业级项目实战

NLP 企业级项目实战

推荐的企业级项目实战

阶段一 夯实AI基础：数据分析与数据结构

阶段二 掌握AI核心：大数据/ML/DL

阶段三 CV NLP 推荐项目实战